GRUPO 8

El grupo presentó un notebook consolidado, ordenado por integrante y con una conclusión común. Se valora especialmente que los cuatro análisis incluyan una descripción del dataset, exploración inicial, visualizaciones y algunas interpretaciones. También es acertado que la elección final se vincule con las posibilidades de continuar posteriormente con la limpieza, formulación de una problemática y construcción de modelos. No obstante, antes de considerar completamente cumplida la entrega, deberán revisar los siguientes aspectos:

Dataset Delivery Market Argentina: Este apartado presenta una exploración completa de dimensiones, tipos de datos, nulos, estadística descriptiva e inconsistencias categóricas. Es una fortaleza que hayan identificado diferentes maneras de registrar una misma ciudad o aplicación y la presencia de valores extremos. Sin embargo, deben revisar algunas interpretaciones:

- En el primer gráfico indican que, por la falta de limpieza, no es posible distinguir la aplicación más utilizada; pero luego afirman que `PedidosYa` y `Rappi` concentran más del 60 % de los pedidos. Antes de sostener ese porcentaje, deben unificar valores como "`PedidosYa`", "`Pedidos Ya`", "`pedidos ya`" y "`PeYa`", y mostrar el cálculo correspondiente.
- En el gráfico de distancia y monto, la interpretación es demasiado general: *explica qué podría observarse, pero no comunica qué se encontró efectivamente*.
- Sería conveniente diferenciar entre un dato atípico y un dato erróneo. Una entrega a 59,3 km o de 180 minutos puede ser extrema, pero no necesariamente incorrecta.
- Deberían indicar la fuente y aclarar si se trata de datos reales, simulados o generados con fines educativos.

Dataset Housing: Se aplican varias funciones de exploración. No obstante, gran parte del apartado describe qué hace cada función, pero falta profundizar en lo que los resultados permiten conocer sobre el dataset. Algunas cuestiones por revisar:

- En `pairplot`, no resulta conveniente utilizar `price` como `hue`, porque es una variable numérica continua con gran cantidad de valores. Podrían usar como color una categoría, por ejemplo, *el estado del amoblamiento, la existencia de aire acondicionado o la ubicación en zona preferencial*.
- El primer gráfico relaciona precio con cantidad de habitaciones, no precio con superficie. La explicación posterior menciona metros cuadrados, ambientes y baños, aunque el gráfico no muestra todas esas relaciones.
- El histograma indica que los precios se concentran entre *"$0,4 y $0,6", pero la escala muestra valores expresados en millones. Deberían interpretar correctamente la unidad, por ejemplo, entre aproximadamente 4 y 6 millones.*
- En el gráfico de precio promedio por cantidad de habitaciones conviene aclarar que las barras representan una estimación del promedio y no la distribución de la cantidad de propiedades.
- Falta una sección final de observaciones generales que sintetice la calidad de los datos, los patrones identificados y las variables más relevantes.

Dataset Matrícula y secciones: El gráfico denominado "*Distribución de establecimientos por ámbito*" cuenta filas del dataset. Para llamarlo cantidad de establecimientos, primero deben comprobar que cada fila representa efectivamente un establecimiento. Por lo observado, las filas parecen corresponder a combinaciones agregadas de provincia, departamento, sector y ámbito. Lo mismo sucede con la afirmación "*Buenos Aires concentra la mayor matrícula*". El gráfico presentado cuenta registros por provincia y sector, pero no suma la matrícula. Para analizar la matrícula deberían sumar las columnas `lactantes`, `deambulantes`, `s2`, `s3` y `s4`, y luego agrupar el resultado por provincia. También deben verificar la interpretación de los valores faltantes. Es posible que una celda vacía represente ausencia de oferta, pero eso debe confirmarse con el diccionario o la documentación de la fuente. No conviene asumir automáticamente que todos los nulos equivalen a cero. Se recomienda igualmente citar con precisión el organismo, el enlace o archivo de origen y explicar qué representa cada fila.

Dataset de ventas de videojuegos: Este apartado presenta una estructura clara, buenas explicaciones y una adecuada distinción entre videojuegos únicos y registros mensuales. También es positivo que, para contar títulos por género, se eliminen las repeticiones mensuales.De todos modos, deben considerar lo siguiente:

- Las variables se presentan explícitamente como **simuladas**. Esto no impide trabajar con ellas, pero debe aclararse su procedencia, cómo fueron generadas y qué limitaciones introduce su carácter sintético.
- Existen 172 videojuegos y registros mensuales para 2024 y 2025. Si todos tuvieran 24 meses, deberían existir 4128 registros, pero el dataset contiene 4096. Conviene verificar si algunos títulos tienen meses faltantes.
- La caracterización de la asociación entre presupuesto y ventas como "*positiva moderada*" debería acompañarse con una medida cuantitativa, como un coeficiente de correlación.
- Al sumar ventas mensuales y compararlas con un presupuesto fijo, deben comprobar que la cantidad de meses observados sea igual para todos los títulos.

Conclusión y selección del dataset: El equipo eligió **Delivery Market Argentina** y expuso argumentos pertinentes: cantidad de variables, necesidad de limpieza, presencia de nulos, valores extremos y posibilidades de modelado. Sin embargo, la conclusión explica principalmente las cualidades del dataset elegido y no evidencia suficientemente la comparación con las otras tres alternativas. Para fortalecerla, podrían incorporar criterios comunes, por ejemplo:

- cumplimiento de dimensiones;
- calidad y trazabilidad de la fuente;
- proporción de datos faltantes;
- variedad y utilidad de las variables;
- existencia de una variable objetivo posible;
- pertinencia de la problemática;
- posibilidades reales de entrenamiento y validación.

Además, expresiones como "*nivel de suciedad ideal"* deberían reformularse en términos más técnicos, por ejemplo: ***"presenta problemas de calidad identificables que permiten aplicar técnicas de limpieza y preparación de datos".***

La entrega evidencia trabajo grupal y una buena organización general, pero requiere correcciones antes de considerarse plenamente ajustada a la consigna. Los cambios prioritarios son: ***Corregir las interpretaciones que no coinciden con lo que muestran los gráficos. Diferenciar cantidad de registros, cantidad de establecimientos y matrícula total. Profundizar el EDA del dataset Housing. Informar la fuente y el carácter real o simulado de cada dataset. Reforzar la conclusión mediante una comparación explícita entre las cuatro alternativas.*** Con estas correcciones, el notebook no solo cumplirá formalmente con la consigna, sino que también mostrará una lectura más crítica y fundamentada de los datos.

Las correcciones son para fortalecer el aprendizaje, eso no invalida el reconocimiento del esfuerzo realizado. ¡Felicitaciones hicieron un muy buen trabajo inicial!